

FACULTAD DE INGENIERÍA Y CIENCIAS COMPUTACIONALES

DEPARTAMENTO DE INTELIGENCIA ARTIFICIAL Y ROBÓTICA

Asignatura: Sistemas Inteligentes / Aprendizaje Automático Supervisado

REPORTE TÉCNICO DE PRÁCTICA EXPERIMENTAL

Clasificación de Enfermedades Foliares mediante Vision Transformers (ViT) y Evaluación de Métricas de Exactitud (ACC)

Técnica Asignada:	Transformers (Vision Transformers - ViT)
Problemática:	Diagnóstico Fitosanitario y Clasificación de Patologías en Hojas
Métrica Principal:	Accuracy (ACC), Matriz de Confusión y F1-Score
Dataset Evaluado:	3,663 Imágenes Foliares en 4 Clases Patológicas (A, B, C, D)

Integrantes del Equipo:

Equipo de Inteligencia Artificial
Ingeniería en Sistemas Computacionales

Docente Evaluador:

Profesor de la Asignatura
Sistemas Inteligentes

1. Introducción

El sector agrícola enfrenta desafíos constantes debido a la incidencia de plagas y patógenos foliares, los cuales representan una de las principales causas de pérdidas económicas en los cultivos a nivel mundial. La detección temprana y precisa de anomalías patológicas en las hojas de las plantas es esencial para implementar tratamientos agroecológicos dirigidos, prevenir la dispersión de infecciones y mitigar el uso indiscriminado de plaguicidas químicos.

Tradicionalmente, el monitoreo fitosanitario ha dependido de la inspección visual manual por parte de expertos agrónomos, un proceso que resulta costoso, lento y propenso a la subjetividad humana en grandes extensiones agrícolas. Con el avance de la visión computacional y el aprendizaje automático supervisado, los sistemas basados en redes neuronales han permitido automatizar la clasificación de imágenes con alta exactitud.

En esta práctica se aborda la problemática de clasificación de enfermedades en hojas vegetales empleando la arquitectura puntera de Vision Transformers (ViT). A diferencia de las redes convolucionales clásicas (CNN), los Transformers capturan relaciones globales y dependencias de largo alcance en el tejido foliar mediante autoatención (Self-Attention), posibilitando una clasificación precisa y una interpretabilidad visual directa sobre los focos de infección.

Objetivos Principales de la Práctica:

- Implementar una arquitectura Vision Transformer (ViT) adaptada para clasificación fitopatológica en 4 clases.
- Evaluar rigurosamente el rendimiento predictivo mediante la métrica de Accuracy (ACC), F1-Score y Matriz de Confusión.
- Analizar la capacidad de atención visual mediante mapas de calor (Attention Rollout) para la localización de lesiones.
- Desarrollar un prototipo interactivo funcional para el diagnóstico de hojas foliares en tiempo real.

2. Marco Teórico (Algoritmos y Fundamentos Matemáticos)

Los Transformers, introducidos originalmente por Vaswani et al. (2017) para el procesamiento de lenguaje natural (NLP), revolucionaron el aprendizaje profundo al prescindir de recurrencias y basarse exclusivamente en el mecanismo de autoatención. Posteriormente, Dosovitskiy et al. (2020) adaptaron este paradigma a la visión artificial con el modelo Vision Transformer (ViT), demostrando que las imágenes pueden procesarse de manera análoga a secuencias de palabras.

2.1. Arquitectura del Vision Transformer (ViT)

El flujo de procesamiento de una imagen en un modelo ViT consta de las siguientes etapas fundamentales:

- Parcheo de Imagen (Patch Embedding):** La imagen bidimensional x en $\mathbb{R}^{(H \times W \times C)}$ se divide en una cuadrícula no superpuesta de N parches de tamaño $P \times P$, donde $N = (HW) / P^2$. Cada parche se aplanar y se proyecta linealmente a un espacio vectorial de dimensión D mediante una matriz de pesos aprendible W_E en $\mathbb{R}^{((P^2 C) \times D)}$.
- Token de Clasificación [CLS] y Codificación Posicional:** Se antepone a la secuencia un vector aprendible x_{class} (token [CLS]). Dado que el mecanismo de autoatención es invariante a permutaciones espaciales, se suma una codificación posicional unidimensional E_{pos} en $\mathbb{R}^{((N+1) \times D)}$ para preservar la estructura geométrica foliar: $z_0 = [x_{class}; x_{p^1} W_E; \dots; x_{p^N} W_E] + E_{pos}$.
- Bloques Encoder y Mecanismo de Multi-Head Self-Attention (MHSA):** Cada bloque está compuesto por normalización de capas (LayerNorm), un módulo de autoatención multi-cabezal y un perceptrón multicapa (MLP).

con conexiones residuales.

Ecuación Fundamental de Autoatención Escalada (Scaled Dot-Product Attention):

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{Q \cdot K^T}{\sqrt{d_k}} \right) \cdot V$$

2.2. Métricas de Evaluación de Aprendizaje Supervisado

Para cuantificar el desempeño del clasificador se emplean las métricas estándar de clasificación multiclase:

- Exactitud / Accuracy (ACC): Proporción de predicciones correctas sobre el total de muestras evaluadas: $\text{ACC} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$.
- Precisión (Precision): Proporción de verdaderos positivos sobre el total de instancias predichas como positivas: $P = \text{TP} / (\text{TP} + \text{FP})$.
- Sensibilidad / Exhaustividad (Recall): Capacidad del modelo de identificar todas las muestras reales de la clase: $R = \text{TP} / (\text{TP} + \text{FN})$.
- F1-Score: Media armónica balanceada entre Precisión y Recall: $F1 = 2 * (P * R) / (P + R)$.

3. Experimentación y Metodología

La experimentación se estructuró de manera metódica para garantizar reproducibilidad y validez estadística. A continuación se detallan las características del conjunto de datos, las técnicas de aumentación y los hiperparámetros de entrenamiento.

3.1. Descripción y Distribución del Dataset Foliar

El conjunto de datos provisto está conformado por un total de 3,663 imágenes RGB con resolución base de 256x256 píxeles, catalogadas en cuatro condiciones fitopatológicas bien diferenciadas:

Clase	Condición / Patología	Muestras	Train (70%)	Val (15%)	Test (15%)
A	Mancha Foliar / Bacteriana (Spot)	363	254	54	55
B	Tizón Foliar / Roya (Late Blight / Rust)	922	645	138	139
C	Moho Foliar (Leaf Mold)	990	693	148	149
D	Hoja Sana (Healthy Leaf)	1,388	971	208	209
TOTAL	Conjunto Completo de Datos	3,663	2,563	548	552

3.2. Procesamiento y Aumentación de Datos (Data Augmentation)

Para evitar el sobreajuste (overfitting) y simular variaciones de iluminación y perspectiva comunes en campo, se aplicó un pipeline de aumentación en tiempo de entrenamiento compuesto por: Redimensionamiento a 224x224x3, Volteo horizontal aleatorio ($p=0.5$), Volteo vertical aleatorio ($p=0.3$), Rotación aleatoria (-20° a $+20^\circ$) y Modificación de brillo, contraste y saturación (ColorJitter 0.2). Finalmente, las imágenes se normalizaron empleando la media y desviación estándar estándar de ImageNet.

3.3. Configuración de Hiperparámetros y Entrenamiento

Hiperparámetros del Modelo Vision Transformer:

- Tamaño de parche (Patch Size): 16 x 16 píxeles (196 parches espaciales por imagen).
- Dimensión de Embedding (D): 192 vectores de proyección lineal.
- Profundidad del Encoder: 6 Bloques Transformer en cascada con 6 cabezales de autoatención por bloque.
- Optimizador: AdamW con tasa de aprendizaje inicial $lr = 3e-4$ y regularización L2 (weight decay = 0.01).
- Función de Pérdida: Cross-Entropy con suavizado de etiquetas (Label Smoothing = 0.05).
- Programador de Aprendizaje (Scheduler): CosineAnnealingLR durante 12 épocas con tamaño de lote (batch size) = 32.

4. Análisis y Discusión de Resultados

El modelo Vision Transformer alcanzó una precisión global en el conjunto de prueba (Test Accuracy - ACC) de 98.37%, con un Macro F1-Score de 98.49%, demostrando una excelente capacidad de discriminación en las cuatro patologías.




Figura 1: Curvas de convergencia de función de pérdida (Cross-Entropy Loss) y exactitud (Accuracy - ACC) por época.

Como se observa en la Figura 1, la función de pérdida disminuye de forma monotonía y estable, alcanzando la convergencia alrededor de la época 8. La regularización mediante AdamW y Label Smoothing evitó el sobreajuste severo, manteniendo una estrecha correlación entre las curvas de entrenamiento y validación.

4.1. Reporte Cuantitativo de Clasificación por Patología

Clase	Descripción Patológica	Precisión	Recall	F1-Score	Soporte
Clase A	Mancha Foliar (Bacterial Spot)	98.21%	100.00%	99.10%	55
Clase B	Tizón Foliar (Late Blight)	98.57%	99.28%	98.92%	139
Clase C	Moho Foliar (Leaf Mold)	99.31%	95.97%	97.61%	149
Clase D	Hoja Sana (Healthy)	97.64%	99.04%	98.34%	209
PROMEDIO GLOBAL (MACRO AVG / ACC)		98.43%	98.57%	98.49%	ACC: 98.4%

4.2. Análisis de Matriz de Confusión e Interpretabilidad Visual




Figura 2: Matriz de Confusión en conteos absolutos y normalizada por clase en el conjunto de prueba.

El análisis de la matriz de confusión revela que la Clase D (Hoja Sana) presenta la mayor especificidad con más del 97% de acierto. Las pocas confusiones registradas ocurrieron principalmente entre la Clase B (Tizón Foliar) y la Clase C (Moho Foliar), debido a que en etapas avanzadas de necrosis ambas enfermedades producen coloraciones pardas oscuras similares en los bordes foliares.




Figura 3: Mapa de Autoatención (Attention Rollout) superpuesto sobre la hoja infectada para interpretabilidad clínica.

5. Conclusiones y Trabajo Futuro

A partir de la experimentación y análisis cuantitativo desarrollado en este proyecto, se desprenden las siguientes conclusiones fundamentales:

1. La arquitectura Vision Transformer (ViT) demostró una extraordinaria capacidad para la clasificación fitosanitaria, alcanzando un Accuracy global de 98.37%, superando el umbral requerido para aplicaciones de monitoreo agronómico.
2. El mecanismo de Multi-Head Self-Attention demostró ser especialmente ventajoso frente a convoluciones estándar, ya que permite focalizar simultáneamente lesiones dispersas en diferentes regiones de la lámina foliar sin perder el contexto global de la hoja.

3. La generación de mapas de atención (Attention Rollout) dota al modelo de interpretabilidad clínica (Explainable AI - XAI), permitiendo a los productores agrícolas y agrónomos validar visualmente las zonas donde el sistema detectó la anomalía.
4. El prototipo interactivo desarrollado en Flask integra la inferencia en tiempo real con recomendaciones terapéuticas y preventivas, constituyendo una herramienta funcional lista para su despliegue en campo.